

Predykcja profilu ADMET z wykorzystaniem multi-task learning

Jakub Cieniuch, Laura Musioł, Ivan Verbovetskyi

1. Repozytorium kodu

Link do repozytorium: [verba05/ADMET-predictor](https://github.com/verba05/ADMET-predictor) (repozytorium publiczne)

2. Dane

W ramach projektu wykorzystane zostaną zbiory danych z **benchmarku TDC**, obejmujące kluczowe parametry profilu ADMET (Absorpcja, Dystrybucja, Metabolizm, Wydalanie, Toksyczność). Wybrane zestawy danych zostaną dobrane tak, aby reprezentowały zróżnicowane zadania: regresję, klasyfikację, zbiory o różnych licznosciach danych. Dane zostaną pobrane przy użyciu biblioteki PyTDC.

3. Metody

- a) Modele klasyczne nauczania maszynowego - 2 modele single-task i jeden model MTL
- b) Modele głębokie - 2 sieci neuronowe single-task i jedna sieć MTL

Dokładne modele zostaną wybrane na dalszym etapie tworzenia projektu. Zależy nam na pokazaniu większego przeglądu różnie działających narzędzi - stąd decyzja o skorzystaniu zarówno z tradycyjnych modeli nauczania maszynowego jak i sieci neuronowych. Ponadto ADMET umożliwia realizację zarówno modeli regresji jak i klasyfikacji - w zależności od wybranych endpointów, co dodatkowo podkreśla sens użycia większej liczby modeli.

Podane informacje to wstępny plan, który naszym zdaniem pozwoli na realizację tego celu. Jednocześnie ilość i dokładny rodzaj metod może ulec zmianie pod wpływem napotkanych problemów albo innych czynników wpływających na zmianę decyzji.

Do implementacji zostaną wykorzystane biblioteki takie jak [m.in.](https://moin.molinspire.org/) scikit-learn, PyTorch, matplotlib, numpy, pandas, RDKit, TDC.

4. Problemy

Podczas pracy z modelami ML i NN możemy napotkać kilka głównych rodzajów problemów:

1. **Problemy z danymi** - wstępna analiza danych wykazała kilka potencjalnych źródeł problemów: nierównowaga klas, znaczne różnice w licznosci zbiorów i niewielka liczba danych dla niektórych endpointów
2. **Problemy techniczne** - modele ML i sieci neuronowe generują duże koszty obliczeniowe, dokładne potrzeby są ciężkie do przewidzenia na tym etapie projektu
3. **Problemy walidacyjne** - overfitting (np. spowodowany małą ilością danych)